Le Web -Activité « Pagerank »

Cette activité permet d'expérimenter la mise en œuvre de **l'algorithme PageRank** dans une version très simplifiée. Le moteur de recherche a sélectionné un certain nombre de pages représentés par des lettres.

On considère ici un internaute qui clique **au hasard** sur un hyperlien présent sur une page et ainsi de suite.

Problématique : quel site possède la plus grande popularité ?

I/ Simulation du PageRank à l'aide d'un dé

Voici un **graphe orienté** représentant les liens existants entre 4 pages Web.
Une flèche signifie qu'il existe un hyperlien allant de la page actuelle vers la page ciblée.

Voici les hyperliens présents par page :

- La page **A** permet de visiter la page B ou la page D ou de rester sur la page A.
- La page **B** permet de visiter la page C ou la page D.
- La page **C** permet de visiter la page C ou la page D.
- La page **D** permet de visiter la page C.

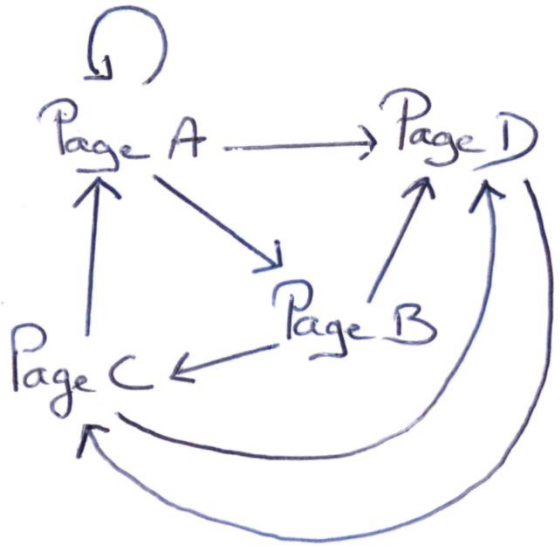

Le programme Python suivant permet de simuler le jet d'un dé à 6 faces non truqué (ou non pipé).

```
from random import randint

print(randint(1,6))
```

A l'aide ce programme à recopier et exécuter sur **https://pyfiddle.io/, simuler 50 clics au hasard d'un internaute**. **En déduire** le pourcentage de visite de chaque site et celui qui semble le plus populaire.

Page A : **Page C :**

Page B : **Page D :**

(-Oral-) Comparer les résultats obtenus, pourquoi sont-ils différents ? Comment faire pour limiter la **dispersion** des résultats ?

Appeler le professeur pour validation.

II/ Programmation du PageRank à l'aide de Python

Voici un programme écrit en Python permettant de simuler l'algorithme PageRank du graphe orienté précédent.

1/ **Ecrire** ce programme sur Python.

```
from random import choice
from random import randint

# Répertorie les sites enregistrés par le moteur de recherche
nom = ["A","B","C","D"]

# Taille de la liste nom
szNom = len(nom)

# Répertorie les hyperliens sortants de chaque site (à faire en fonction du graphe)
# 0 correspond au site "A", 1 correspond au site B etc.
hyperliens = [[0,1,3],[2,3],[0,3],[2]]

# Demande du nombre de tests souhaités converti en entier
# Ne pas dépasser 1 millions de tests
nbEtapes = int(input("Nombre de tests souhaités : "))

# Déclaration et initialisation de variables
nbVisites = []              # Nombre de fois où chaque site est visité
for i in range(0,szNom) :
    nbVisites.append(0)     # Crée le tableau souhaité en fonction du nombre de sites

page = randint(0,szNom)     # Site actuellement visité, valeur aléatoire au départ

for i in range(nbEtapes) :
    # Permet de sélectionner aléatoirement le futur site visité PARMI
    # les hyperliens disponibles du site en question
    page = choice(hyperliens[page])

    # On incrémente le nombre de fois où le site ainsi visité
    nbVisites[page] = nbVisites[page] + 1


# Pourcentage de visite de chaque site et affichage des résultats
for i in range(0,szNom) :
    nbVisites[i] = 100.0 * nbVisites[i] / nbEtapes  # Conversion implicite en float
    print(nom[i] + " = " + str(nbVisites[i]) + " %") # Affichage des résultats
```

2/ **Tester** pour 100 ; 1 000 ; 10 000 ; 100 000 et 1 000 000 de tests. **Compléter** le tableau ci-dessous après chaque test.

Nbre.Tests	**100**	**1 000**	**10 000**	**100 000**	**1 000 000**
%.Chaque.Page	Page A : Page B : Page C : Page D :	Page A : Page B : Page C : Page D :	Page A : Page B : Page C : Page D :	Page A : Page B : Page C : Page D :	Page A : Page B : Page C : Page D :

3/ **En déduire** quelle page est la plus populaire en **justifiant** la réponse.

.....

III/ Améliorer la popularité d'un site

Voici un autre graphe orienté représentant une autre situation.

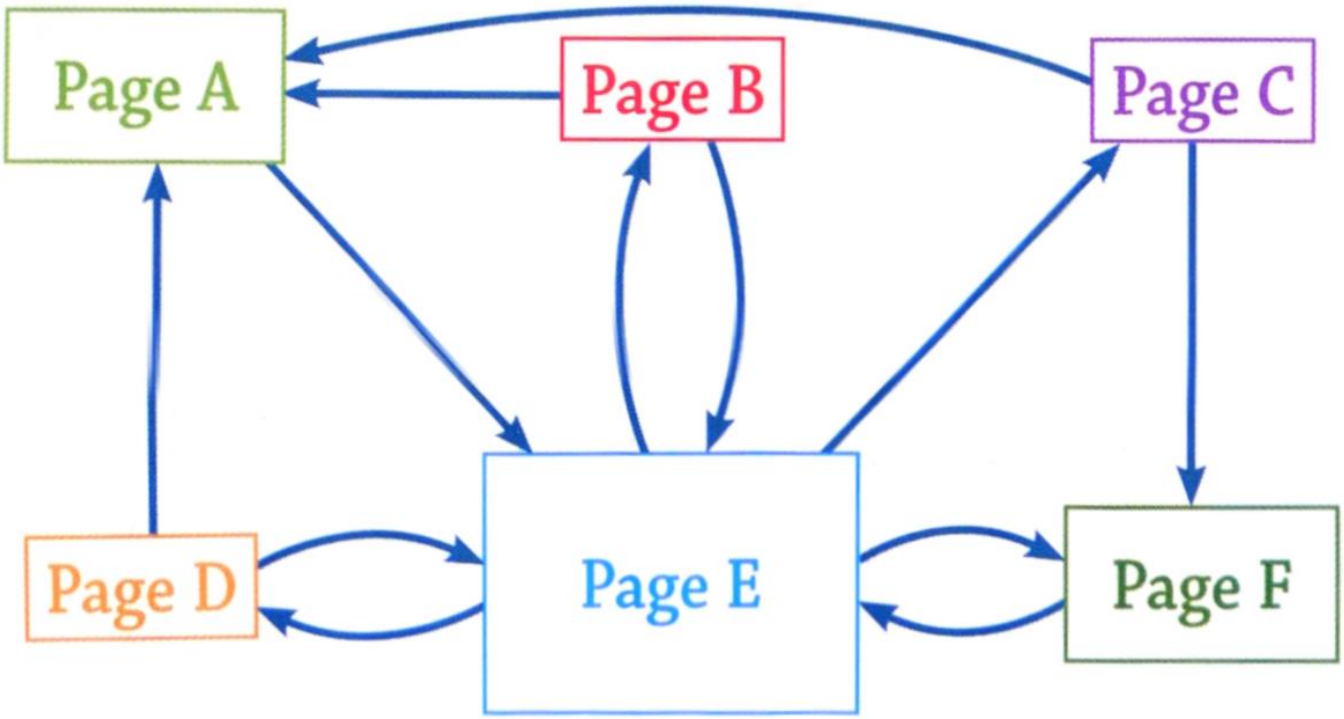

1/ **Modifier** le programme précédent pour qu'il corresponde à ce graphe orienté.

2/ **Tester** pour 100 ; 1 000 ; 10 000 ; 100 000 et 1 000 000 de tests. **Compléter** le tableau ci-dessous après chaque test.

Nbre.Tests	**100**	**1 000**	**10 000**	**100 000**	**1 000 000**
%.Chaque.Page	Page A : Page B : Page C : Page D : Page E : Page F :	Page A : Page B : Page C : Page D : Page E : Page F :	Page A : Page B : Page C : Page D : Page E : Page F :	Page A : Page B : Page C : Page D : Page E : Page F :	Page A : Page B : Page C : Page D : Page E : Page F :

3/ **Vérifier** que si l'on remplace le lien de la page A vers la page E par un lien de la page A vers la page C, les popularités de A et C augmentent.

Aide : on modifiera le programme pour répondre à la question.

4/ **Expliquer** ce phénomène.

.....

.....

.....

IV/ Aller plus loin : les matrices de transition

1/ Tout comme pour les arbres pondérés, **compléter** les probabilités d'aller d'une page à l'autre.

Exemple :

De la page C, on peut aller à la page A ou F. Il y a donc une probabilité de 0,5 d'aller à la page A (ou F).

0,5

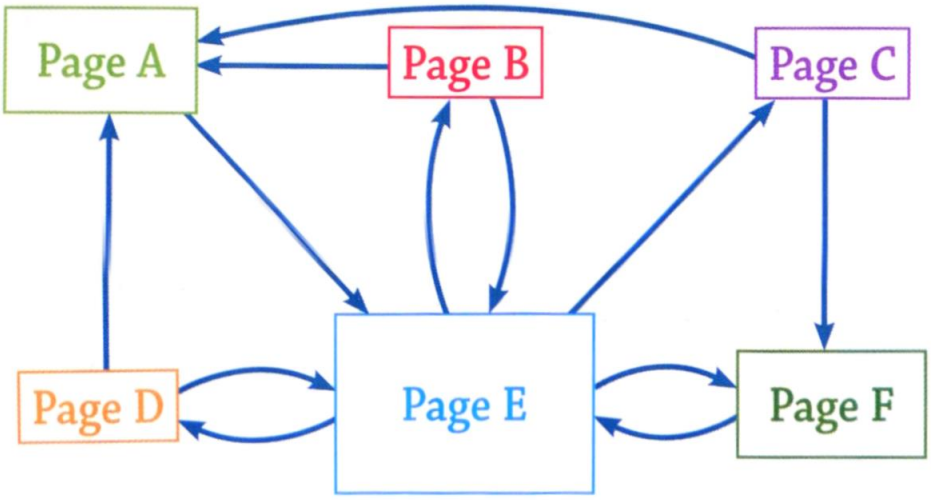

2/

Compléter le tableau suivant.
Remarque : on écrira 0 s'il n'y a aucun lien.

Ce tableau (sans les cellules en bleu) représente une **matrice de transition** d'un état au suivant. En multipliant successivement suffisamment de fois cette matrice par elle-même, on est capable d'estimer l'état final qui correspond ici à la popularité de chaque site grâce aux valeurs de chaque colonne.

Vers	A	B	C	D	E	F
A	0	0	0	0	1	0
B						
C	0.5					
D						
E						
F						

3/ **Aller** sur le site https://matrixcalc.org/fr/

Compléter la matrice A (il faut cliquer sur « + » pour augmenter le nombre de lignes/colonnes), **cocher** « Montrer les nombres décimaux » à **2 décimales, l'élever à la puissance 100** et **appuyer** sur entrée.

Important : écrire les nombres décimaux avec un point comme séparateur et non une virgule.

Vérifier alors que les résultats de chaque colonne correspondent à la popularité trouvée par le programme Python de chaque page.

Appeler le professeur pour validation.